

Thuật toán xây dựng ô-tô-mát hậu tố tổng quát và các chặn không gian

Mehryar Mohri, Pedro Moreno, Eugene Weinstein

Nguồn gốc: General Suffix Automaton Construction Algorithm and Space Bounds

english/general-suffix-automaton-construction-algorithm-and-space-bounds.pdf

Abstract

Ô-tô-mát hậu tố và ô-tô-mát nhân tố là các cấu trúc dữ liệu hiệu quả để biểu diễn chỉ mục đầy đủ của một tập xâu. Chúng là các ô-tô-mát hữu hạn đơn định tối thiểu biểu diễn tập mọi hậu tố hoặc mọi xâu con của một tập xâu. Bài viết này đưa ra một phân tích mới về kích thước của ô-tô-mát hậu tố và ô-tô-mát nhân tố của một tập xâu. Cụ thể, ô-tô-mát hậu tố hoặc ô-tô-mát nhân tố của tập xâu U có nhiều nhất $2Q - 2$ trạng thái, trong đó Q là số nút của cây tiền tố biểu diễn các xâu trong U . Chặn này cải thiện đáng kể so với chặn $2\|U\| - 1$ của Blumer và cộng sự (1987), trong đó $\|U\|$ là tổng độ dài các xâu trong U . Tổng quát hơn, bài viết đưa ra các chặn mới cho kích thước của ô-tô-mát hậu tố hoặc nhân tố của một ô-tô-mát theo kích thước của ô-tô-mát ban đầu và độ dài lớn nhất của một hậu tố chung giữa các xâu mà nó chấp nhận. Bài viết cũng mô tả chi tiết một thuật toán thời gian tuyến tính để xây dựng ô-tô-mát hậu tố S hoặc ô-tô-mát nhân tố F của U trong thời gian $O(|S|)$. Thuật toán thật ra áp dụng được cho mọi ô-tô-mát đầu vào hậu-tố-duy-nhất và tổng quát hóa chặt chẽ cách xây dựng trực tuyến chuẩn của ô-tô-mát hậu tố cho một xâu đơn. Thuật toán cũng có thể dùng trực tiếp để tạo oracle hậu tố hoặc oracle nhân tố của một tập xâu, vốn có nhiều tính chất hữu ích trong khớp xâu. Phân tích cho thấy việc dùng ô-tô-mát nhân tố của ô-tô-mát có thể khả thi trong các ứng dụng quy mô lớn; điều này cũng được củng cố bởi thực nghiệm trên một bài toán nhận dạng nhạc với hơn 15,000 bài hát.

Từ khóa: khớp xâu, khớp mẫu, chỉ mục, văn bản đảo, ô-tô-mát hữu hạn, cây hậu tố, ô-tô-mát hậu tố, ô-tô-mát nhân tố, nhận dạng nhạc.

1 Giới thiệu

Tìm kiếm mẫu trong những khối lượng rất lớn văn bản ngôn ngữ tự nhiên, chuỗi sinh học và các chuỗi số hóa dễ truy cập khác là một vấn đề trung tâm của khoa học máy tính. Bài toán có nhiều ứng dụng và đã được nghiên cứu rộng rãi [1, 2].

Bài viết này xét bài toán xây dựng một chỉ mục đầy đủ, hay tệp đảo, cho một tập xâu được biểu diễn bằng ô-tô-mát hữu hạn. Khi số xâu lớn, chẳng hạn hàng nghìn hoặc hàng triệu xâu, cả tập có thể được lưu gọn dưới dạng ô-tô-mát, đồng thời cho phép cài đặt hiệu quả các thuật toán tìm kiếm và những thuật toán khác [3, 4]. Trong nhiều ngữ cảnh như nhận dạng tiếng nói hoặc trích xuất thông tin, toàn bộ tập xâu thường được cho trực tiếp dưới dạng một ô-tô-mát.

Một cấu trúc dữ liệu hiệu quả và gọn để biểu diễn chỉ mục đầy đủ của một tập xâu là **ô-tô-mát hậu tố**: ô-tô-mát đơn định tối thiểu biểu diễn tập mọi hậu tố của tập xâu. Vì một xâu con là tiền tố của một hậu tố, ô-tô-mát hậu tố có thể dùng để kiểm tra một xâu x có phải là xâu con hay không trong thời gian tuyến tính $O(|x|)$, là tối ưu. Tương tự cây hậu tố, ô-tô-mát hậu tố còn có những tính chất thú vị khác trong các

bài toán khớp xâu, khiến việc dùng và xây dựng nó trở nên hấp dẫn [1, 2]. Một cấu trúc tương tự để biểu diễn chỉ mục đầy đủ là **ô-tô-mát nhân tố**: ô-tô-mát đơn định tối tiểu biểu diễn tập mọi nhân tố, tức mọi xâu con, của một tập xâu. Ô-tô-mát nhân tố có cùng tính chất tìm kiếm tuyến tính tối ưu như ô-tô-mát hậu tố, và không bao giờ lớn hơn nó.

Việc xây dựng và kích thước của ô-tô-mát nhân tố đã được phân tích riêng cho trường hợp một xâu đơn [5, 6]. Các tác giả này chứng minh một kết quả đáng chú ý: kích thước ô-tô-mát nhân tố của một xâu x là tuyến tính; cụ thể, với $|x| > 3$, nó có nhiều nhất $2|x| - 2$ trạng thái và $3|x| - 4$ cung. Họ cũng đưa ra thuật toán trực tuyến thời gian tuyến tính để xây dựng ô-tô-mát nhân tố từ x . Những kết quả tương tự cũng đúng cho ô-tô-mát hậu tố, tức ô-tô-mát đơn định tối tiểu chấp nhận đúng tập hậu tố của một xâu.

Việc xây dựng và kích thước của ô-tô-mát nhân tố của một tập hữu hạn $U = \{x_1, \dots, x_m\}$ cũng đã được nghiên cứu [7]. Các tác giả chỉ ra rằng có thể xây dựng một ô-tô-mát chấp nhận mọi nhân tố của U với nhiều nhất $2\|U\| - 1$ trạng thái và $3\|U\| - 3$ cung, trong đó

$$\|U\| = \sum_{i=1}^m |x_i|$$

là tổng độ dài của mọi xâu trong U .

Bài viết này chứng minh một chặn tốt hơn đáng kể cho kích thước của ô-tô-mát hậu tố hoặc ô-tô-mát nhân tố của một tập xâu. Cụ thể, chúng có nhiều nhất $2Q - 2$ trạng thái, trong đó Q là số nút của cây tiền tố biểu diễn các xâu trong U . Số nút Q có thể nhỏ hơn rất nhiều so với $\|U\|$, nên chặn không gian này cải thiện rõ rệt so với kết quả trước [7]. Tổng quát hơn, chúng tôi đưa ra các chặn mới cho kích thước ô-tô-mát hậu tố hoặc nhân tố của một ô-tô-mát hữu hạn phi chu trình, theo kích thước của ô-tô-mát ban đầu và độ dài lớn nhất của một hậu tố chung giữa các xâu được chấp nhận. Kết quả này có thể so sánh với kết quả của Inenaga và cộng sự cho đồ thị từ phi chu trình có hướng dạng nén, có độ phức tạp $O(|\Sigma|Q)$ phụ thuộc vào kích thước bảng chữ cái [8].

Dựa trên phân tích chặn không gian, chúng tôi cũng đưa ra một thuật toán đơn giản để xây dựng ô-tô-mát hậu tố S hoặc ô-tô-mát nhân tố F của U trong thời gian $O(|S|)$ từ cây tiền tố biểu diễn U . Thuật toán thật ra áp dụng cho mọi ô-tô-mát đầu vào hậu-tố-duy-nhất và tổng quát hóa chặt chẽ phép xây dựng trực tuyến chuẩn của ô-tô-mát hậu tố cho một xâu đơn.

Động cơ ban đầu của công trình là thiết kế một hệ thống nhận dạng nhạc quy mô lớn [4, 9]. Trong hệ thống đó, cơ sở dữ liệu bài hát được biểu diễn bằng một ô-tô-mát hữu hạn gọn. Để tìm kiếm nhanh các đoạn nhạc ngắn, chúng tôi xây dựng ô-tô-mát nhân tố đơn định tối tiểu của ô-tô-mát bài hát. Thực nghiệm cho thấy kích thước ô-tô-mát nhân tố không quá lớn. Tuy nhiên, để bảo đảm khả năng mở rộng tới tập bài hát lớn hơn, chẳng hạn vài triệu bài, ta cần một chặn cho kích thước ô-tô-mát nhân tố của ô-tô-mát. Trong ứng dụng này cũng như trong nhiều ứng dụng khác, các xâu gốc không chia sẻ các hậu tố dài. Điều đó dẫn tới phân tích kích thước ô-tô-mát nhân tố theo độ dài các hậu tố chung trong ô-tô-mát ban đầu.

Phần còn lại của bài viết được tổ chức như sau. Mục 2 giới thiệu các định nghĩa và thuật ngữ về xâu và ô-tô-mát. Mục 3 trình bày phân tích mới về ô-tô-mát nhân tố và các chặn mới cho kích thước ô-tô-mát hậu tố và nhân tố của một ô-tô-mát. Mục 4 mô tả chi tiết thuật toán thời gian tuyến tính để xây dựng ô-tô-mát hậu tố và nhân tố của một tập hữu hạn các xâu, hoặc của một ô-tô-mát hậu-tố-duy-nhất bất kỳ, kèm mã giả. Mục 5 mô tả ngắn việc dùng ô-tô-mát nhân tố trong nhận dạng nhạc và báo cáo một số kết quả thực nghiệm về kích thước của chúng.

2 Nhân tố của một ô-tô-mát hữu hạn

Mục này nhắc lại một số tính chất then chốt của các nhân tố của một ô-tô-mát hữu hạn cố định, tổng quát hóa các quan sát tương tự của Blumer và cộng sự cho một xâu đơn [7].

Ký hiệu Σ là một bảng chữ cái hữu hạn. Độ dài của xâu $x \in \Sigma^*$ trên bảng chữ cái đó được ký hiệu là $|x|$. Một **nhân tố**, hay xâu con, của x là một dãy ký hiệu xuất hiện liên tiếp trong x . Vì vậy, y là nhân tố của x khi và chỉ khi tồn tại $u, v \in \Sigma^*$ sao cho $x = uyv$. Một **hậu tố** của x là một nhân tố xuất hiện ở cuối x ; tương đương, y là hậu tố của x khi và chỉ khi tồn tại $u \in \Sigma^*$ sao cho $x = uy$. Tương tự, y là **tiền tố** của x khi và chỉ khi tồn tại $u \in \Sigma^*$ sao cho $x = yu$. Tổng quát hơn, nhân tố, hậu tố hoặc tiền tố của một tập xâu U , hoặc của một ô-tô-mát A , là nhân tố, hậu tố hoặc tiền tố của một xâu trong U , hoặc của một xâu được A chấp nhận. Ký hiệu ϵ biểu diễn xâu rỗng; với mọi $x \in \Sigma^*$, ϵ luôn là tiền tố, hậu tố và nhân tố của x .

Định nghĩa 1 Cho k là một số nguyên không âm. Ta nói ô-tô-mát hữu hạn A là **k -hậu-tổ-duy-nhất** nếu không có hai xâu nào được A chấp nhận cùng chia sẻ một hậu tố độ dài k . Ta gọi A là **hậu-tổ-duy-nhất** khi nó là k -hậu-tổ-duy-nhất với $k = 1$.

Ví dụ chạy trong bài là một ô-tô-mát đơn giản chấp nhận ba xâu $ac, acab, acba$; ba xâu kết thúc bằng các ký hiệu khác nhau, nên ô-tô-mát này là hậu-tổ-duy-nhất.

Các kết quả chính của bài viết đúng cho ô-tô-mát hậu-tổ-duy-nhất, nhưng một số kết quả cũng được trình bày cho trường hợp tổng quát của ô-tô-mát phi chu trình bất kỳ. Ký hiệu $F(A)$ là ô-tô-mát đơn định tối tiểu chấp nhận tập các nhân tố của ô-tô-mát hữu hạn A , tức tập các nhân tố của những xâu được A chấp nhận. Tương tự, $S(A)$ là ô-tô-mát đơn định tối tiểu chấp nhận tập các hậu tố của A .

Định nghĩa 2 Cho A là một ô-tô-mát hữu hạn. Với mọi $x \in \Sigma^*$, định nghĩa $\text{end-set}(x)$ là tập trạng thái của A đạt được bởi những đường đi trong A bắt đầu bằng x . Ta nói hai xâu $x, y \in \Sigma^*$ tương đương, ký hiệu $x \equiv y$, khi $\text{end-set}(x) = \text{end-set}(y)$. Đây là một quan hệ tương đương bất biến phải trên Σ^* . Ký hiệu $[x]$ là lớp tương đương của x .

Bổ đề 1 Giả sử A là hậu-tổ-duy-nhất. Khi đó, một nhân tố x không phải hậu tố của A là phần tử dài nhất của $[x]$ khi và chỉ khi x là tiền tố của A , hoặc cả ax và bx đều là nhân tố của A với hai ký hiệu phân biệt $a, b \in \Sigma$.

Chứng minh. Cho x là một nhân tố không phải hậu tố của A . Nếu x không phải tiền tố, rõ ràng phải có hai ký hiệu phân biệt a, b sao cho ax và bx là nhân tố của A ; nếu không, $[x]$ sẽ chứa một phần tử dài hơn.

Ngược lại, giả sử ax và bx đều là nhân tố của A với $a \neq b$. Gọi y là phần tử dài nhất của $[x]$. Lấy $q \in \text{end-set}(x) = \text{end-set}(y)$. Vì x không phải hậu tố, q không phải trạng thái kết thúc, nên tồn tại một xâu không rỗng z gán nhãn cho một đường đi từ q tới trạng thái kết thúc. Do A là hậu-tổ-duy-nhất, cả xz và yz là hậu tố của cùng một xâu. Vì y dài nhất trong $[x]$, x phải là hậu tố của y . Nhưng do ax và bx cùng là nhân tố với $a \neq b$, suy ra bắt buộc $y = x$. Cuối cùng, nếu x là tiền tố, hiển nhiên nó là phần tử dài nhất của $[x]$. $\dashv$

Với ô-tô-mát ở ví dụ chạy trên, ô-tô-mát hậu tố $S(A)$ có thể đọc như sau: các trạng thái của $S(A)$ chính là những lớp tương đương của các hậu tố và các tiền tố của chúng.

Mệnh đề 1 Giả sử A là hậu-tổ-duy-nhất. Xét ô-tô-mát đơn định $S_A = (Q_S, I_S, F_S, E_S)$ có tập trạng thái

$$Q_S = \{[x] \neq \emptyset : x \in \Sigma^*\},$$

trạng thái đầu $I_S = \{[\epsilon]\}$, tập trạng thái kết thúc

$$F_S = \{[x] : \text{end-set}(x) \cap F_A \neq \emptyset\},$$

trong đó F_A là tập trạng thái kết thúc của A , và tập cung

$$E_S = \{([x], a, [xa]) : [x], [xa] \in Q_S\}.$$

Khi đó S_A là ô-tô-mát hậu tố đơn định tối tiểu của A , tức $S_A = S(A)$.

Chứng minh. Theo xây dựng, S_A đơn định và chấp nhận đúng tập hậu tố của A . Cho $[x]$ và $[y]$ là hai trạng thái tương đương của S_A . Khi đó, với mọi $z \in \Sigma^*$, $[xz] \in F_A$ khi và chỉ khi $[yz] \in F_A$, nghĩa là xz là hậu tố của A khi và chỉ khi yz là hậu tố của A . Vì A là hậu-tổ-duy-nhất, điều này kéo theo x là hậu tố của y hoặc ngược lại; do đó $[x] = [y]$. Vì vậy S_A tối tiểu. $\dashv$

Trong phần sau, ta quan tâm tới trường hợp ô-tô-mát A là phi chu trình. Ký hiệu $|A|_Q$ là số trạng thái của A , $|A|_E$ là số cung của A , và $|A|$ là kích thước của A , tức tổng số trạng thái và số cung.

3 Chặn không gian cho ô-tô-mát nhân tố

Mục tiêu của mục này là suy ra các chặn mới cho kích thước của $S(A)$ và $F(A)$ trong trường hợp quan trọng với ứng dụng của chúng tôi: A là một ô-tô-mát phi chu trình, thường đơn định và tối tiểu, biểu diễn một tập xấu.

Khi A biểu diễn một xâu đơn, đã có các thuật toán chuẩn xây dựng $S(A)$ và $F(A)$ từ A trong thời gian tuyến tính [5, 6]. Trong trường hợp tổng quát, $S(A)$ có thể được xây dựng từ A như sau: thêm một cung ϵ từ trạng thái đầu của A tới mỗi trạng thái của A , sau đó khử ϵ , đơn định hóa và tối tiểu hóa. $F(A)$ có thể thu được tương tự bằng cách thêm bước biến mọi trạng thái thành kết thúc trước khi khử ϵ , đơn định hóa và tối tiểu hóa. Nó cũng có thể thu được từ $S(A)$ bằng cách biến mọi trạng thái của $S(A)$ thành kết thúc rồi tối tiểu hóa.

Khi A biểu diễn một xâu đơn x , kích thước của $S(A)$ và $F(A)$ là tuyến tính theo $|x|$. Chính xác hơn [6, 5],

$$\begin{aligned} |S(A)|_Q &\leq 2|x| - 1, & |S(A)|_E &\leq 3|x| - 4, \\ |F(A)|_Q &\leq 2|x| - 2, & |F(A)|_E &\leq 3|x| - 4. \end{aligned} \quad (1)$$

Các chặn này là chặt với các xâu có độ dài lớn hơn ba. Blumer và cộng sự [7] đưa ra kết quả tương tự cho tập xâu U :

$$|F(U)|_Q \leq 2\|U\| - 1, \quad |F(U)|_E \leq 3\|U\| - 3. \quad (2)$$

Nhìn chung, kích thước của một ô-tô-mát phi chu trình A biểu diễn một tập hữu hạn U có thể nhỏ hơn rất nhiều so với $\|U\|$; thật ra $|A|$ có thể nhỏ hơn theo cấp số mũ. Vì thế, ta muốn chặn kích thước $S(A)$ hoặc $F(A)$ theo kích thước của A , thay vì theo tổng độ dài mọi xâu được A chấp nhận.

Với mỗi trạng thái q của $S(A)$, ký hiệu $\text{suff}(q)$ là tập các xâu gán nhãn cho những đường đi từ q tới một trạng thái kết thúc. Ký hiệu $N(q)$ là tập các trạng thái trong A mà từ đó có một đường đi gán nhãn bằng một xâu không rỗng thuộc $\text{suff}(q)$ tới một trạng thái kết thúc.

Bổ đề 2 Cho A là ô-tô-mát hậu-tổ-duy-nhất và q, q' là hai trạng thái của $S(A)$ sao cho $N(q) \cap N(q') \neq \emptyset$. Khi đó

$$\begin{aligned} (\text{suff}(q) \subseteq \text{suff}(q') \text{ và } N(q) \subseteq N(q')) \\ \text{hoặc } (\text{suff}(q') \subseteq \text{suff}(q) \text{ và } N(q') \subseteq N(q)). \end{aligned} \quad (3)$$

Chứng minh. Vì $S(A)$ tối tiểu, mọi trạng thái của nó đều truy cập được từ trạng thái đầu. Gọi u là nhãn của một đường đi từ trạng thái đầu I của $S(A)$ tới q , và tương tự gọi u' là nhãn của một đường đi từ I tới q' .

Theo giả thiết, tồn tại $p \in N(q) \cap N(q')$. Do đó tồn tại các xâu không rỗng $v \in \text{suff}(q)$ và $v' \in \text{suff}(q')$ sao cho cả v và v' đều gán nhãn cho đường đi từ p tới trạng thái kết thúc.

Theo định nghĩa của u và u' , cả uv và $u'v'$ đều là hậu tố của A . Vì A là hậu-tổ-duy-nhất và v không rỗng, chỉ có một xâu được A chấp nhận kết thúc bằng v . Cũng chỉ có một xâu được A chấp nhận kết thúc bằng $u'v'$. Hai xâu đó phải trùng nhau.

Suy ra mọi xâu được A chấp nhận và có hậu tố v cũng có hậu tố uv . Đặc biệt, nhãn của mọi đường đi từ trạng thái đầu tới p phải có hậu tố u . Lập luận tương tự với v' cho thấy nhãn đó cũng phải có hậu tố u' . Vậy u và u' là hậu tố của cùng một xâu; do đó u là hậu tố của u' hoặc ngược lại: nếu uv và $u'v$ là hậu tố của cùng một xâu x , thì u và u' là hai hậu tố lồng nhau của x .

Không mất tính tổng quát, giả sử u là hậu tố của u' . Khi đó với mọi w , nếu $u'w$ là hậu tố của A thì uw cũng là hậu tố của A . Vì vậy $\text{suff}(q') \subseteq \text{suff}(q)$, kéo theo $N(q') \subseteq N(q)$. Trường hợp u' là hậu tố của u cho kết luận còn lại. $\dashv$

Bổ đề 2 vẫn đúng ngay cả khi A là ô-tô-mát không đơn định.

Bổ đề 3 Cho A là ô-tô-mát đơn định hậu-tổ-duy-nhất và q, q' là hai trạng thái phân biệt của $S(A)$ sao cho $N(q) = N(q')$. Khi đó hoặc q là trạng thái kết thúc còn q' không phải, hoặc q' là trạng thái kết thúc còn q không phải.

Chứng minh. Giả sử $N(q) = N(q')$. Theo Bổ đề 2, suy ra $\text{suff}(q) = \text{suff}(q')$. Do đó cùng các xâu không rỗng gán nhãn cho các đường đi từ q tới trạng thái kết thúc cũng gán nhãn cho các đường đi từ q' tới trạng thái kết thúc. Vì $S(A)$ tối thiểu, hai trạng thái phân biệt q và q' không tương đương. Vậy một trong hai trạng thái phải cho phép đường đi rỗng tới trạng thái kết thúc, còn trạng thái kia thì không. $\dashv$

Mệnh đề 2 Cho A là ô-tô-mát đơn định, tối thiểu, hậu-tổ-duy-nhất, chấp nhận các xâu có độ dài lớn hơn ba. Khi đó số trạng thái của ô-tô-mát hậu tố của A thỏa

$$|S(A)|_Q \leq 2|A|_Q - 3. \quad (4)$$

Chứng minh. Nếu mọi xâu được A chấp nhận đều có dạng a^n , thì $S(A)$ thu được đơn giản bằng cách biến mọi trạng thái của A thành trạng thái kết thúc, và chặn hiển nhiên đúng. Vì vậy, phần còn lại giả sử không phải mọi xâu được chấp nhận đều có dạng này.

Gọi F là trạng thái kết thúc duy nhất của $S(A)$ không có cung ra. Bổ đề 2 và 3 cho phép định nghĩa một cây T trên mọi trạng thái của $S(A)$ trừ F , theo thứ tự

$$N(q) \sqsubseteq N(q') \iff \begin{cases} N(q) \subset N(q'), & \text{hoặc} \\ N(q) = N(q') \text{ và } q' \text{ kết thúc, còn } q \text{ không kết thúc.} \end{cases} \quad (5)$$

Ta đồng nhất mỗi nút của T với trạng thái tương ứng trong $S(A)$. Theo Mệnh đề 1, mỗi trạng thái q của $S(A)$ cũng được đồng nhất với một lớp tương đương $[x]$. Với $q \neq F$, nếu $[x]$ là lớp tương ứng thì, do A là hậu-tổ-duy-nhất, $\text{end-set}(x)$ trùng với $N(q)$.

Ta chứng minh số nút của T nhiều nhất là $2|A|_Q - 4$; từ đó suy ra chặn cần chứng minh cho $S(A)$. Ta chặn riêng số nút phân nhánh và không phân nhánh của T .

Cho q là một nút của T , $[x]$ là lớp tương ứng, với x là phần tử dài nhất của lớp. Con của q là các nút tương ứng với các lớp $[ax]$, trong đó $a \in \Sigma$ và ax là nhân tố của A .

Theo Bổ đề 1, nếu x là nhân tố không phải hậu tố và không phải tiền tố, thì tồn tại hai nhân tố ax và bx với $a \neq b$. Vì thế q có ít nhất hai con tương ứng với $[ax]$ và $[bx]$, nên là nút phân nhánh. Do đó nút không phân nhánh chỉ có thể là nút mà x là tiền tố, hoặc nút mà x là hậu tố, tức trạng thái kết thúc của $S(A)$.

Vì các xâu được A chấp nhận không phải đều có dạng a^n , tiền tố rỗng ϵ xuất hiện trong ít nhất hai ngữ cảnh trái khác nhau a và b với $a \neq b$. Vì vậy tiền tố ϵ , tương ứng với gốc của T , chắc chắn phân nhánh. Gọi f là trạng thái kết thúc duy nhất của A không có cung ra. Lớp tương đương của nhân tố dài nhất kết thúc tại f , tức xâu dài nhất được A chấp nhận, tương ứng với trạng thái F của $S(A)$ và không nằm trong T . Vậy có nhiều nhất $|A|_Q - 2$ tiền tố không phân nhánh.

Mặt khác, với mỗi xâu được A chấp nhận có nhiều nhất một nút không phân nhánh tương ứng với hậu tố. Gọi N_{str} là số xâu được A chấp nhận. Khi đó số nút không phân nhánh N_{nb} của T thỏa

$$N_{\text{nb}} \leq |A|_Q - 2 + N_{\text{str}}.$$

Để chặn số nút phân nhánh N_b , quan sát rằng do A là hậu-tổ-duy-nhất, mỗi xâu được A chấp nhận kết thúc bằng một ký hiệu riêng a_i , $i = 1, \dots, N_{\text{str}}$. Mỗi a_i là một ngữ cảnh trái khác nhau của nhân tố rỗng ϵ , nên nút gốc $[\epsilon]$ có các con $[a_i]$. Gọi T_{a_i} là cây con gốc $[a_i]$ và n_{a_i} là số lá của nó. Gọi a_j , $j = N_{\text{str}} + 1, \dots, N_{\text{str}} + k$, là các con khác của gốc, và T_{a_j} là các cây con tương ứng. Một cây có n_{a_i} lá có ít hơn n_{a_i} nút phân nhánh, nên số nút phân nhánh của T_{a_i} nhiều nhất là $n_{a_i} - 1$. Tổng số lá của T nhiều nhất là số tập con rời nhau của Q , bỏ trạng thái đầu và f .

Nếu gốc chỉ có các con $[a_i]$, tức $k = 0$, thì tồn tại ít nhất một a_i , gọi là a_1 , cũng là tiền tố của A ; nếu có ký hiệu khác thì nó đã là con của gốc. Nút a_1 khi đó cũng có con vì nó tương ứng với một hậu tố, tức một trạng thái kết thúc của $S(A)$. Do đó a_1 không thể là lá trong trường hợp này. Vì vậy

$$\sum_{i=1}^{N_{\text{str}}+k} n_{a_i} \leq |A|_Q - 2 - \mathbf{1}_{k=0}.$$

Tổng số nút phân nhánh của T , kể cả gốc, nhiều nhất là

$$N_b \leq \sum_{i=1}^{N_{\text{str}}+k} (n_{a_i} - 1) + 1 \leq |A|_Q - 2 - \mathbf{1}_{k=0} - (N_{\text{str}} + k) + 1 \leq |A|_Q - 2 - N_{\text{str}}.$$

Suy ra tổng số nút của T nhiều nhất là $N_{\text{nb}} + N_b \leq 2|A|_Q - 4$. $\dashv$

Trong trường hợp riêng A biểu diễn một xâu đơn x , chặn của Mệnh đề 2 khớp với chặn trong [6, 5], vì $|A|_Q = |x| + 1$. Chặn này là chặt với các xâu có độ dài lớn hơn ba, nên cũng chặt cho các ô-tô-mát chấp nhận xâu có độ dài lớn hơn ba. Ô-tô-mát ở ví dụ chạy là hậu-tổ-duy-nhất, đơn định và tối tiểu, có $|A|_Q = 6$ trạng thái; ô-tô-mát hậu tố tối tiểu của nó có $|S(A)|_Q = 7 < 2|A|_Q - 3$.

Hệ quả 1 Cho A là ô-tô-mát đơn định, tối tiểu, hậu-tổ-duy-nhất, chấp nhận các xâu có độ dài lớn hơn ba. Khi đó số trạng thái của ô-tô-mát nhân tố của A thỏa

$$|F(A)|_Q \leq 2|A|_Q - 3. \quad (6)$$

Chứng minh. Như đã nói, $F(A)$ thu được từ $S(A)$ bằng cách biến mọi trạng thái thành kết thúc rồi tối tiểu hóa. Do đó $|F(A)| \leq |S(A)|$, và kết quả suy ra từ Mệnh đề 2. $\dashv$

Blumer và cộng sự (1987) chứng minh rằng một ô-tô-mát chấp nhận mọi nhân tố của một tập xâu U có nhiều nhất $2\|U\| - 1$ trạng thái, trong đó $\|U\|$ là tổng độ dài các xâu trong U [7]. Hệ quả sau cho một chặn tốt hơn đáng kể theo số nút của cây tiền tố biểu diễn U , thường nhỏ hơn nhiều so với $\|U\|$.

Hệ quả 2 Cho $U = \{x_1, \dots, x_m\}$ là một tập xâu có độ dài lớn hơn ba và A là cây tiền tố biểu diễn U . Khi đó số trạng thái của ô-tô-mát nhân tố $F(U)$ và ô-tô-mát hậu tố $S(U)$ của các xâu trong U thỏa

$$|F(U)|_Q \leq 2|A|_Q - 2, \quad |S(U)|_Q \leq 2|A|_Q - 2. \quad (7)$$

Chứng minh. Gọi B là cây tiền tố biểu diễn tập $U' = \{x_1\$1, \dots, x_m\$m\}$, thu được bằng cách gắn vào mỗi xâu của U một ký hiệu mới $\$, i = 1, \dots, m$, để làm các hậu tố phân biệt; gọi B' là ô-tô-mát thu được bằng cách tối tiểu hóa B . Theo xây dựng, B có nhiều hơn A đúng m trạng thái, nhưng vì mọi trạng thái kết thúc của B tương đương và bị nhập lại sau khi tối tiểu hóa, B' có nhiều nhất hơn A một trạng thái.

Theo xây dựng, B' là ô-tô-mát hậu-tổ-duy-nhất. Theo Mệnh đề 2, $|S(B')|_Q \leq 2|B'|_Q - 3$. Xóa khỏi $S(B')$ các cung gán nhãn bởi các ký hiệu phụ $\$_i$ rồi nối ô-tô-mát kết quả ta thu được ô-tô-mát hậu tổ tối tiểu $S(U)$. Trong $S(B')$, phải có một trạng thái kết thúc chỉ đạt được qua các cung gán nhãn $\$_i$; trạng thái này trở nên không truy cập được sau khi xóa ký hiệu phụ. Vì thế $S(U)$ có ít nhất một trạng thái ít hơn $S(B')$, và

$$|S(U)|_Q \leq |S(B')|_Q - 1 \leq 2|B'|_Q - 4 = 2|A|_Q - 2. \quad (8)$$

Chặn tương tự cho $F(U)$ suy ra theo lập luận trong chứng minh Hệ quả 1. $\dashv$

Khi A là k -hậu-tổ-duy-nhất với k tương đối nhỏ, như trong các ứng dụng chúng tôi quan tâm, mệnh đề sau cho một chặn tiện dụng cho kích thước ô-tô-mát hậu tổ.

Mệnh đề 3 Cho A là ô-tô-mát đơn định k -hậu-tổ-duy-nhất chấp nhận các xâu có độ dài lớn hơn ba, và n là số xâu được A chấp nhận. Khi đó số trạng thái của ô-tô-mát hậu tổ của A thỏa

$$|S(A)|_Q \leq 2|A_k|_Q + 2kn - 3, \quad (9)$$

trong đó A_k là phân của ô-tô-mát A thu được bằng cách bỏ các trạng thái và cung của mọi hậu tổ độ dài k .

Chứng minh. Cho A là ô-tô-mát đơn định k -hậu-tổ-duy-nhất chấp nhận các xâu có độ dài lớn hơn ba, và mở rộng bảng chữ cái Σ bằng n ký hiệu tạm $\$_1, \dots, \$_n$. Bằng cách đánh dấu mỗi xâu được A chấp nhận bằng một ký hiệu riêng $\$_i$, ta biến A thành một ô-tô-mát đơn định hậu-tổ-duy-nhất A' .

Để làm vậy, trước hết ta trải phẳng mọi hậu tổ độ dài k của A . Trong trường hợp xấu nhất, mọi hậu tổ phân biệt này trước đó cùng chia sẻ một hậu tổ độ dài $k - 1$; việc trải phẳng khi đó có thể làm tăng số trạng thái của A thêm tối đa $kn - n$ trạng thái. Đánh dấu cuối mỗi hậu tổ bằng một ký hiệu $\$_i$ riêng làm tăng thêm n trạng thái. Ô-tô-mát kết quả A' là đơn định và $|A'|_Q \leq |A_k|_Q + kn$. Theo Mệnh đề 2, $|S(A')|_Q \leq 2|A'|_Q - 3$. Vì các cung gán nhãn $\$_i$ chỉ có thể xuất hiện ở cuối đường đi thành công trong $S(A')$, ta có thể xóa các cung này, biến trạng thái xuất phát của chúng thành kết thúc, rồi tối thiểu hóa ô-tô-mát thu được để nhận ô-tô-mát đơn định A'' chấp nhận tập hậu tổ của A . Kết luận của mệnh đề suy ra từ $|A''|_Q \leq |S(A')|_Q$. $\dashv$

Vì kích thước $F(A)$ luôn không lớn hơn kích thước $S(A)$, ta có ngay hệ quả sau.

Hệ quả 3 Cho A là ô-tô-mát k -hậu-tổ-duy-nhất chấp nhận các xâu có độ dài lớn hơn ba. Khi đó ô-tô-mát nhân tổ của A thỏa

$$|F(A)|_Q \leq 2|A_k|_Q + 2kn - 3. \quad (10)$$

Chặn trong hệ quả này không chặt với các giá trị k tương đối nhỏ: trong thực tế, kích thước ô-tô-mát nhân tổ không phụ thuộc vào kn , tổng độ dài các hậu tổ độ dài k , mà phụ thuộc nhiều hơn vào số trạng thái của A dùng để biểu diễn chúng; với ô-tô-mát tối tiểu, số này có thể nhỏ hơn đáng kể. Tuy nhiên, với k lớn, chẳng hạn khi mọi xâu có cùng độ dài và k bằng đúng độ dài các xâu được A chấp nhận, chặn của chúng tôi trùng với chặn của [7].

4 Thuật toán xây dựng ô-tô-mát hậu tổ

Mục này mô tả một thuật toán thời gian tuyến tính để xây dựng ô-tô-mát hậu tổ $S(A)$ của một ô-tô-mát đầu vào hậu-tổ-duy-nhất A , hoặc tương tự là ô-tô-mát nhân tổ $F(A)$ của A . Vì ô-tô-mát nhân tổ có thể thu được từ $S(A)$ bằng cách biến mọi trạng thái của $S(A)$ thành kết thúc rồi áp dụng thuật toán tối tiểu

hóa ô-tô-mát đơn định phi chu trình thời gian tuyến tính [11], chỉ cần mô tả thuật toán thời gian tuyến tính cho $S(A)$. Tuy nhiên, cũng có thể đưa ra một thuật toán trực tiếp tương tự cho $F(A)$.

Các thuật toán dưới đây xây dựng $S(A) = (Q_S, I, F_S, \delta_S)$ từ $A = (Q_A, I, F_A, \delta_A)$, trong đó A là hậu-tổ-duy-nhất, $\delta_S : Q_S \times \Sigma \rightarrow Q_S$ là hàm chuyển bộ phận của $S(A)$, và $\delta_A : Q_A \times \Sigma \rightarrow Q_A$ là hàm chuyển bộ phận của A . Như ở mục trước, f là trạng thái kết thúc của A không có cung ra. Ta gọi đích của liên kết hậu tố là **con trở hậu tố**.

```

CREATE-SUFFIX-AUTOMATON( $A, f$ )
1   $S \leftarrow Q_S \leftarrow \{I\}$ 
2   $s[I] \leftarrow \text{undefined}; l[I] \leftarrow 0$ 
3  while  $S \neq \emptyset$  do
4     $p \leftarrow \text{Head}(S)$ 
5    for each cung  $(p, a, q)$  của  $A$  do
6      if  $q \neq f$  then
7         $Q_S \leftarrow Q_S \cup \{q\}$ 
8         $l[q] \leftarrow l[p] + 1$ 
9        SUFFIX-NEXT( $p, a, q$ )
10       Enqueue( $S, q$ )
11   $Q_S \leftarrow Q_S \cup \{f\}$ 
12  for each trạng thái  $p \in Q_A$  và  $a \in \Sigma$  sao cho  $\delta_A(p, a) = f$  do
13    SUFFIX-NEXT( $p, a, f$ )
14    SUFFIX-FINAL( $f$ )
15  for each  $p \in F_A$  do
16    SUFFIX-FINAL( $p$ )
17  return  $S(A) = (Q_S, I, F_S, \delta_S)$ 

```

Thuật toán là một tổng quát hóa của phép xây dựng chuẩn cho một xâu đầu vào sang trường hợp đầu vào là ô-tô-mát hậu-tổ-duy-nhất. Nó duy trì hai giá trị $s[q]$ và $l[q]$ cho mỗi trạng thái q của $S(A)$. $s[q]$ là con trở hậu tố, hay trạng thái thất bại, của q . $l[q]$ là độ dài đường đi dài nhất từ trạng thái đầu tới q trong $S(A)$. Giá trị l được dùng để xác định các cung đặc, hay chuyển tiếp đặc, trong quá trình xây dựng: cung (p, a, q) là đặc nếu $l[p] + 1 = l[q]$, tức nó nằm trên một đường đi dài nhất từ trạng thái đầu tới q ; nếu không, nó là cung tắt.

S là hàng đợi chứa các trạng thái cần xét. Kỷ luật hàng đợi cụ thể không ảnh hưởng tới tính đúng đắn; có thể giả sử dùng FIFO, tương ứng với duyệt theo chiều rộng và có cài đặt tuyến tính. Trong mỗi vòng lặp dòng 3–10, một trạng thái mới p được lấy ra từ S . Việc xử lý các cung (p, a, f) có đích là f được hoãn tới giai đoạn sau (dòng 12–14). Lý do là f có tính chất đặc biệt: như đã thảo luận ở mục trước, nó có thể được xem là con của nhiều nút khác nhau của cây T , nên có thể có các liên kết hậu tố khác nhau. Các cung khác (p, a, q) được xử lý lần lượt bằng cách tạo trạng thái đích q nếu cần, thêm nó vào Q_S , xác định $l[q]$ và gọi SUFFIX-NEXT(p, a, q).

SUFFIX-NEXT(p, a, q)

```

1   $l[q] \leftarrow \max(l[p] + 1, l[q])$ 
2  while  $p \neq I$  và  $\delta_S(p, a) = \text{undefined}$  do
3     $\delta_S(p, a) \leftarrow q$ 
4     $p \leftarrow s[p]$ 
5  if  $\delta_S(p, a) = \text{undefined}$  then
6     $\delta_S(I, a) \leftarrow q$ 
7     $s[q] \leftarrow I$ 
8  elseif  $l[p] + 1 = l[\delta_S(p, a)]$  và  $\delta_S(p, a) \neq q$  then
9     $s[q] \leftarrow \delta_S(p, a)$ 
10 else  $r \leftarrow q$ 
11   if  $\delta_S(p, a) \neq q$  then
12      $r \leftarrow$  bản sao của  $\delta_S(p, a)$  với cùng các cung ra
13      $Q_S \leftarrow Q_S \cup \{r\}$ 
14      $s[q] \leftarrow r$ 
15      $s[r] \leftarrow s[\delta_S(p, a)]$ 
16      $s[\delta_S(p, a)] \leftarrow r$ 
17      $l[r] \leftarrow l[p] + 1$ 
18   while  $p \neq \text{undefined}$  và  $l[\delta_S(p, a)] \geq l[r]$  do
19      $\delta_S(p, a) \leftarrow r$ 
20    $p \leftarrow s[p]$ 

```

SUFFIX-FINAL(p)

```

1  if  $p \in F_S$  then
2     $p \leftarrow s[p]$ 
3  while  $p \neq \text{undefined}$  và  $p \notin F_S$  do
4     $F_S \leftarrow F_S \cup \{p\}$ 
5     $p \leftarrow s[p]$ 

```

Thủ tục SUFFIX-NEXT xử lý mỗi cung (p, a, q) rất giống phép xây dựng ô-tô-mát hậu tố chuẩn cho một xâu. Vòng lặp dòng 2–4 duyệt các con trở hậu tố lặp của p chưa có cung ra gắn nhãn a . Nó tạo các cung như vậy tới q từ mọi con trở hậu tố lặp cho tới khi gặp trạng thái đầu hoặc một trạng thái p' đã có cung này. Trong trường hợp thứ nhất, con trở hậu tố của q được đặt là trạng thái đầu I và cung (I, a, q) được tạo.

Trong trường hợp thứ hai, nếu cung sẵn có (p', a, q') là cung đặc và $q' = q$, thì con trở hậu tố của q được đặt là q' (dòng 9). Nếu $q' \neq q$, tạo một bản sao r của q' với cùng các cung ra (dòng 12) và đặt con trở hậu tố của q là r . Con trở hậu tố của r được đặt thành $s[q']$ (dòng 15), con trở của q' được đặt thành r (dòng 16), và $l[r]$ được định nghĩa là $l[p] + 1$ (dòng 17). Các cung gắn nhãn a đi ra từ các con trở hậu tố lặp của p được xét và chuyển hướng tới r miễn là chúng là các cung không đặc (dòng 18–20).

Thủ tục SUFFIX-FINAL đặt tính kết thúc của các trạng thái trong $S(A)$. Với mọi trạng thái p kết thúc trong A , trạng thái p và mọi trạng thái tìm được bằng cách đi theo chuỗi con trở hậu tố bắt đầu từ p đều được đưa vào F_S trong vòng lặp dòng 3–5.

Có thể theo dõi thuật toán bằng cách ghi mỗi trạng thái trung gian dưới dạng $(n/s, l)$, trong đó n là số hiệu trạng thái, s là con trở hậu tố của nó, và l là giá trị $l[n]$; các giai đoạn xây dựng $S(A)$ chỉ thay đổi các cung, con trở hậu tố và giá trị l theo đúng các dòng trong hai thủ tục trên.

Trong phép xây dựng **suffix oracle** [10], không có trạng thái mới nào được tạo so với đầu vào. Do đó oracle hậu tố của A có thể được xây dựng tương tự bằng cách thay dòng 12 trong SUFFIX-NEXT bởi $r \leftarrow \delta_S(p, a)$ và bỏ các dòng 15–17. Thuật toán này vì thế mở rộng trực tiếp phép xây dựng oracle hậu tố

sang trường hợp đầu vào là ô-tô-mát hậu-tổ-duy-nhất.

Với kết quả độ phức tạp sau, ta giả sử hàm chuyển được biểu diễn hiệu quả để có thể tìm trong thời gian $O(1)$ một cung ra có nhãn cụ thể tại mỗi trạng thái. Một số tác giả giả sử biểu diễn danh sách kề và tìm kiếm nhị phân để tìm cung tại một trạng thái, tốn $O(\min\{\log |\Sigma|, e_{\max}\})$, trong đó $e_{\max}$ là bậc ra lớn nhất [6, 2]. Nếu dùng giả thiết đó, các kết quả độ phức tạp ở đây cũng như của Blumer và cộng sự [5, 7] cần nhân thêm hệ số $\min\{\log |\Sigma|, e_{\max}\}$.

Ta gọi việc chuyển hướng một cung đã từng được chuyển hướng trước đó là **chuyển hướng nhiều lần**.

Mệnh đề 4 Cho A là ô-tô-mát đơn định tối thiểu hậu-tổ-duy-nhất. Khi đó độ phức tạp thời gian của thuật toán $CREATE-SUFFIX-AUTOMATON(A, f)$ là $O(|S(A)|)$.

Chứng minh. Ta phác thảo chứng minh. SUFFIX-NEXT được gọi nhiều nhất một lần cho mỗi cung, nên tổng số lời gọi là $O(|A|)$. Cố định một cung (p, a, q) của A với $q \neq f$. Chi phí thực hiện các bước 1–20 của SUFFIX-NEXT tỉ lệ với tổng số lần đi theo liên kết hậu tổ lặp trong các vòng lặp dòng 2–4 và 18–20. Mỗi lần lặp của dòng 2–4 tạo ra một cung mới trong $S(A)$, nên tổng số lần lặp này trên mọi lời gọi SUFFIX-NEXT là $O(|S(A)|)$.

Phân tích tổng số lần chuyển hướng trong vòng lặp dòng 18–20 dựa trên một mở rộng của phân tích cho trường hợp một xâu đơn [12, 7]. Chặn tuyến tính cho tổng số lần chuyển hướng trong trường hợp một xâu đơn áp dụng được cho trường hợp ô-tô-mát của chúng ta trên một chuỗi tuyến tính các trạng thái của A . Từ tổ hợp xâu con cần thiết trong A để gây ra chuyển hướng, có thể chứng minh tổng số chuyển hướng nhiều lần là $O(|A|)$. Do đó độ phức tạp tổng là $O(|S(A)|)$. $\dashv$

5 Ô-tô-mát nhân tố cho nhận dạng nhạc

Chúng tôi kiểm chứng các nhận xét trên về ô-tô-mát nhân tố trong ngữ cảnh một hệ thống nhận dạng nhạc [4, 9]. Nhận dạng nhạc là nhiệm vụ khớp một luồng âm thanh với một bài hát cụ thể. Trong hệ thống này, ta học một kho đơn vị **music phone** tương tự âm vị trong tiếng nói, cùng một dãy music phone duy nhất đặc trưng cho mỗi bài hát. Tập music phone được xem như bảng chữ cái, còn các dãy music phone là tập xâu; bài toán trở thành một bài toán nhận dạng nhân tố. Cách tiếp cận là xây dựng một bộ chuyển đổi gọn ánh xạ các dãy music phone tới định danh bài hát tương ứng.

5.1 Xây dựng bộ chuyển đổi nhân tố


Ký hiệu Σ là tập music phone và tập dãy music phone mô tả m bài hát là $U = \{x_1, \dots, x_m\}$, với $x_i \in \Sigma^*$ cho $i \in \{1, \dots, m\}$. Trong thực nghiệm, $m = 15,455$, $|\Sigma| = 1,024$ và độ dài trung bình của một phiên âm x_i lớn hơn 1,700. Vì vậy trong trường hợp xấu nhất có thể có tới

$$15,455 \times 1,700^2 \approx 45 \times 10^9$$

nhân tố. Một biểu diễn ngây thơ dựa trên cây tiền tố sẽ quá lớn, nên ta biểu diễn tập nhân tố bằng ô-tô-mát nhân tố gọn hơn nhiều. Chúng tôi xây dựng một ô-tô-mát đơn định tối thiểu biểu diễn các dãy trong U , rồi xây dựng một bộ chuyển đổi hữu hạn trạng thái đơn định tối thiểu ánh xạ mỗi bài hát tới định danh của nó bằng các thuật toán đơn định hóa và tối thiểu hóa bộ chuyển đổi [13, 14].

Gọi T_0 là bộ chuyển đổi chưa tối ưu ánh xạ các dãy phone tới định danh bài hát. Khi U chỉ gồm vài bài hát ngắn, T_0 có thể hình dung như một cây tiền tố có nhãn đầu ra ở cuối mỗi bài hát:

Gọi A là acceptor thu được bằng cách bỏ nhãn đầu ra của T_0 . Ô-tô-mát nhân tố gọn $F(A)$ được xây dựng như ở Mục 3: tạo các cung ϵ từ trạng thái đầu của A tới mọi trạng thái khác, biến mọi trạng thái



Hình 1: Sơ đồ minh họa T_0 : mỗi đường từ gốc tới trạng thái kết thúc đọc một bài hát ngắn và xuất định danh của bài hát đó ở cuối đường.

thành kết thúc, rồi khử ϵ , đơn định hóa và tối thiểu hóa. Chú ý rằng $F(A)$ không xuất ra định danh bài hát gắn với mỗi nhân tố.

Để mô tả bước tiếp theo, ta nhắc ngắn một số tính chất của ô-tô-mát có trọng số. Một ô-tô-mát có trọng số được định nghĩa trên một nửa vành $(K, \oplus, \otimes, \bar{0}, \bar{1})$, quy định tập trọng số và các phép toán đại số để kết hợp trọng số dọc theo một đường đi và giữa các đường đi. Nửa vành nhiệt đới


$$(\mathbb{R} \cup \{-\infty, +\infty\}, \min, +, +\infty, 0)$$

được dùng rộng rãi trong các lĩnh vực như xử lý tiếng nói và văn bản. Trong nửa vành nhiệt đới, tổng trọng số mà ô-tô-mát gán cho một xâu s là đường đi có trọng số nhỏ nhất trong ô-tô-mát mang nhãn s , trong đó trọng số của một đường đi được tính bằng tổng trọng số các cung trên đường đi đó.

Để xây dựng ô-tô-mát nhân tố vẫn giữ được định danh bài hát, ta tạo một acceptor có trọng số gọn trên nửa vành nhiệt đới, chấp nhận các nhân tố của U và gán tổng trọng số s_x cho mỗi nhân tố x . Ưu điểm quan trọng của biểu diễn này là có thể dùng đơn định hóa và tối thiểu hóa có trọng số [13]; trong các phép toán đó, định danh bài hát được xem như trọng số có thể phân bố dọc đường đi. Các phép toán bảo toàn tính chất rằng tổng trọng số trên đường đi mang nhãn x là s_x . Gọi $F_w(A)$ là ô-tô-mát được xây dựng tương tự $F(A)$, nhưng mỗi cung ϵ được thêm vào có trọng số là định danh bài hát tương ứng. Sau khi đơn định hóa và tối thiểu hóa trên nửa vành nhiệt đới, acceptor có trọng số $F_w(A)$ được biến thành bộ chuyển đổi nhận dạng bài hát T bằng cách xem mỗi trọng số đầu ra nguyên là một ký hiệu đầu ra. Với một dãy music phone đầu vào, định danh bài hát tương ứng được thu bằng cách cộng các đầu ra do T sinh ra.

5.2 Kích thước ô-tô-mát

Sơ đồ dưới đây tóm tắt khác biệt giữa acceptor nhân tố không trọng số $F(A)$ và acceptor nhân tố có trọng số $F_w(A)$ cho hai bài hát. Trong bản có trọng số, định danh bài hát được đưa vào trọng số trên các cung ϵ ban đầu, nên thông tin bài hát vẫn được giữ sau đơn định hóa và tối thiểu hóa mà không làm tăng kích thước cấu trúc một cách đáng kể.



Hình 2: So sánh khái niệm giữa $F(A)$ và $F_w(A)$: bản có trọng số lưu định danh bài hát như trọng số trên đường đi thay vì bỏ mất thông tin đầu ra.

Đáng chú ý, ngay cả với 15,455 bài hát, tổng số cung của $F_w(A)$ là 53.0 triệu, chỉ nhiều hơn khoảng 0.004% so với $F(A)$. Đồng thời,

$$|F(A)|_E \approx 2.1|A|_E.$$

Quan hệ nhân này được giữ khi kích thước tập bài hát thay đổi từ 1 tới 15,455. Hơn nữa, với 15,455 bài hát, U là 45-hậu-tổ-duy-nhất: số “va chạm” hậu tổ giảm rất nhanh khi độ dài hậu tổ tăng. Thực nghiệm cũng cho

$$|F_w(A)|_Q \approx 28.8 \text{ triệu} \approx 1.2|A|_Q,$$

nghĩa là chặn trong Hệ quả 3 được xác nhận trong bối cảnh thực nghiệm này.

6 Kết luận

Bài viết trình bày một phân tích mới về kích thước của ô-tô-mát hậu tổ và ô-tô-mát nhân tố của một tập xâu được biểu diễn bằng ô-tô-mát, theo kích thước của ô-tô-mát ban đầu. Phân tích cho thấy ô-tô-mát hậu tổ và ô-tô-mát nhân tố có thể thực tế để xây dựng chỉ mục cho số lượng xâu rất lớn. Ứng dụng vào một bài toán nhận dạng nhạc quy mô lớn cũng minh họa thêm điều này. Ô-tô-mát nhân tố của ô-tô-mát nhiều khả năng là một chỉ mục hữu ích và gọn cho các tác vụ quy mô rất lớn.

Bài viết cũng đưa ra thuật toán thời gian tuyến tính để xây dựng ô-tô-mát hậu tổ hoặc ô-tô-mát nhân tố của một tập xâu trong thời gian tuyến tính theo kích thước của cây tiền tố biểu diễn chúng. Thuật toán áp dụng cho mọi ô-tô-mát đầu vào hậu-tổ-duy-nhất và tổng quát hóa chặt chẽ phép xây dựng trực tuyến chuẩn của ô-tô-mát hậu tổ cho một xâu đơn. Thuật toán và phân tích này đặt ra câu hỏi tự nhiên về cách xây dựng hiệu quả ô-tô-mát hậu tổ của một ô-tô-mát đầu vào bất kỳ.

Lời cảm ơn

Các tác giả cảm ơn Cyril Allauzen vì nhiều trao đổi về nội dung trình bày. Nghiên cứu của Mehryar Mohri và Eugene Weinstein được hỗ trợ một phần bởi New York State Office of Science Technology and Academic Research (NYSTAR). Dự án cũng được tài trợ một phần bởi Department of the Army, số tài trợ W81XWH-04-1-0307. U.S. Army Medical Research Acquisition Activity, 820 Chandler Street, Fort Detrick MD 21702-5014 là cơ quan trao và quản lý tài trợ. Nội dung tài liệu không nhất thiết phản ánh lập trường hay chính sách của Chính phủ, và không nên suy diễn thành sự xác nhận chính thức.

References

- [1] D. Gusfield, *Algorithms on Strings, Trees, and Sequences*, Cambridge University Press, Cambridge, UK, 1997.
- [2] M. Crochemore, W. Rytter, *Jewels of Stringology*, World Scientific, 2002.
- [3] C. Allauzen, M. Mohri, M. Saraclar, General Indexation of Weighted Automata: Application to Spoken Utterance Retrieval, in: *Proceedings of the Workshop on Interdisciplinary Approaches to Speech Indexing and Retrieval (HLT/NAACL)*, Boston, Massachusetts, 2004, pp. 33–40.
- [4] E. Weinstein, P. Moreno, Music Identification with Weighted Finite-State Transducers, in: *Proceedings of the International Conference on Acoustics, Speech, and Signal Processing (ICASSP)*, Honolulu, Hawaii, 2007, pp. 689–692.

- [5] A. Blumer, J. Blumer, D. Haussler, A. Ehrenfeucht, M. T. Chen, J. I. Seiferas, The smallest automaton recognizing the subwords of a text, *Theoretical Computer Science* 40 (1985) 31–55.
- [6] M. Crochemore, Transducers and repetitions, *Theoretical Computer Science* 45 (1986) 63–86.
- [7] A. Blumer, J. Blumer, D. Haussler, R. M. McConnell, A. Ehrenfeucht, Complete inverted files for efficient text retrieval and analysis, *Journal of the ACM* 34 (1987) 578–589.
- [8] S. Inenaga, H. Hoshino, A. Shinohara, M. Takeda, S. Arikawa, G. Mauri, G. Pavesi, On-line construction of compact directed acyclic word graphs, *Discrete Applied Mathematics* 146(2) (2005) 156–179.
- [9] M. Mohri, P. Moreno, E. Weinstein, Robust music identification, detection, and analysis, in: Proceedings of the International Conference on Music Information Retrieval (ISMIR), Vienna, Austria, 2007, pp. 135–139.
- [10] C. Allauzen, M. Crochemore, M. Raffinot, Efficient experimental string matching by weak factor recognition, in: Proceedings of the 12th Annual Symposium on Combinatorial Pattern Matching (CPM), Springer-Verlag, London, UK, 2001, pp. 51–72.
- [11] D. Revuz, Minimisation of acyclic deterministic automata in linear time, *Theoretical Computer Science* 92 (1992) 181–189.
- [12] J. A. Blumer, Algorithms for the directed acyclic word graph and related structures, Ph.D. thesis, Denver University, 1985.
- [13] M. Mohri, Finite-state transducers in language and speech processing, *Computational Linguistics* 23(2) (1997) 269–311.
- [14] M. Mohri, Statistical Natural Language Processing, in: M. Lothaire (Ed.), *Applied Combinatorics on Words*, Cambridge University Press, 2005.