

Dãy Con Chung Dài Nhất

Tài liệu bài giảng

Nguồn gốc: *Longest Common Subsequence*

English Materials/Longest common subsequence.pdf

1 Định nghĩa

Dãy con chung dài nhất, hay LCS, của hai chuỗi S_1 và S_2 là dãy con dài nhất xuất hiện trong cả hai chuỗi. Ví dụ, với hai chuỗi được căn chỉnh:

$$\begin{array}{cccccccccccc} S_1 : & A & - & A & T & - & G & G & C & C & - & A & T & A \\ S_2 : & A & T & A & T & A & A & T & T & C & T & A & T & - \end{array}$$

một LCS là AATCAT, có độ dài 6. Lời giải không nhất thiết duy nhất. Với cặp (ATTA, ATAT), các lời giải ATT và ATA đều là dãy con chung dài nhất. Nói chung, với hai chuỗi bất kỳ có thể tồn tại nhiều lời giải.

2 Liên hệ với căn chỉnh và khoảng cách chỉnh sửa

Định lý. Nếu cho điểm 1 cho mỗi ký tự khớp, và điểm 0 cho mỗi ký tự không khớp hoặc ô trống, thì các ký tự khớp trong một căn chỉnh có giá trị cực đại tạo thành một LCS.

Vì cách làm này dùng quy hoạch động tổng quát, độ phức tạp là $O(nm)$, với $n = |S_1|$ và $m = |S_2|$. Bài toán chuỗi con chung dài nhất theo nghĩa đoạn liên tiếp, ngược lại, có lời giải $O(n + m)$. Dãy con phức tạp hơn nhiều so với chuỗi con liên tiếp.

Trong ví dụ ở trên, căn chỉnh tối ưu có ba phép chèn, một phép xóa và ba phép thay thế, nên khoảng cách chỉnh sửa là 7 nếu thay thế có chi phí 1. Nhưng mỗi phép thay thế có thể được thực hiện bằng một phép xóa rồi một phép chèn. Nếu chi phí thay thế là 2, còn chèn và xóa đều có chi phí 1, thì khoảng cách chỉnh sửa nhỏ nhất D liên hệ với độ dài LCS, ký hiệu là L , bởi:

$$D = m + n - 2L.$$

Với ví dụ trên, $n = 10$, $m = 12$, $L = 6$, nên $D = 10$: gồm 6 phép chèn và 4 phép xóa.

3 Tính trực tiếp bằng quy hoạch động

Ta có thể tính LCS trực tiếp bằng quy hoạch động. Cách này hiệu quả hơn về hằng số, dù độ phức tạp tiệm cận vẫn là $O(nm)$. Gọi $L(i, j)$ là độ dài LCS của hai tiền tố $S_1[1..i]$ và $S_2[1..j]$. Khi đó:

$$L(0, 0) = 0,$$

$$L(i, 0) = 0,$$

$$L(0, j) = 0,$$

và với $i, j > 0$:

$$L(i, j) = \begin{cases} 1 + L(i-1, j-1), & S_1(i) = S_2(j), \\ \max\{L(i, j-1), L(i-1, j)\}, & S_1(i) \neq S_2(j). \end{cases}$$

Nếu lưu thêm con trỏ truy vết trong ma trận, ta có thể khôi phục một hoặc nhiều dãy con chung dài nhất.

Ví dụ. Với $S_1 = \text{ATCAAT}$ và $S_2 = \text{TAATCATA}$, một giá trị LCS là 5, nên khoảng cách chỉnh sửa với chi phí thay thế bằng 2 là:

$$6 + 8 - 2 \cdot 5 = 4.$$

Bảng quy hoạch động trong tài liệu gốc ghi các giá trị $L(i, j)$ cho từng tiền tố; hàng cuối cho thấy độ dài cực đại là 5.

4 Một hướng nhanh hơn thông qua LIS

Ta xét một bài toán phụ. Cho π là một dãy gồm n số nguyên, không nhất thiết phân biệt.

Dãy con tăng. Dãy con tăng (LIS theo nghĩa *increasing subsequence*) của π là một dãy con có giá trị tăng nghiêm ngặt từ trái sang phải. Ví dụ:

$$\pi = (5, 3, 4, 4, 9, 6, 2, 1, 8, 7, 10)$$

có các dãy con tăng như $(3, 4, 6, 8, 10)$ và $(5, 9, 10)$. Dãy con tăng dài nhất là dãy con tăng có độ dài cực đại.

Dãy con giảm và phủ. Dãy con giảm ở đây là dãy con không tăng. Ví dụ:

$$(5, 4, 4, 2, 1).$$

Một **phủ** là một tập các dãy con giảm rời nhau của π sao cho mọi phần tử của π đều nằm trong một dãy. Kích thước phủ c là số dãy con giảm trong phủ. Ví dụ:

$$\pi = (5, 3, 4, 9, 6, 2, 1, 8, 7)$$

có phủ

$$\{(5, 3, 2, 1), (4), (9, 6), (8, 7)\},$$

nên $c = 4$. Phủ nhỏ nhất là phủ có c nhỏ nhất.

Bổ đề. Nếu I là một dãy con tăng của π có độ dài bằng kích thước của một phủ C của π , thì I là dãy con tăng dài nhất, và C là phủ nhỏ nhất.

Thật vậy, một dãy con tăng không thể chứa nhiều hơn một phần tử từ cùng một dãy con giảm. Nếu

$$C = C_1 \cup C_2 \cup \dots \cup C_k,$$

thì mọi dãy con tăng có độ dài nhiều nhất $k = |C|$. Ngược lại, nếu có một phủ nhỏ hơn C , dãy con tăng I sẽ buộc phải lấy hơn một phần tử từ một dãy con giảm nào đó của phủ ấy, điều không thể xảy ra.

5 Xây dựng phủ trong thời gian log-tuyến tính

Thuật toán tham lam xây dựng phủ như sau. Duyệt π từ trái sang phải. Với mỗi số hiện tại, chèn nó vào dãy con giảm nằm trái nhất trong các dãy đã tạo sao cho tính không tăng vẫn được giữ. Nếu không chèn được vào dãy nào, bắt đầu một dãy con giảm mới.

Để đạt $O(n \log n)$, lưu một danh sách L gồm phần tử cuối của mỗi dãy con giảm đang xây dựng, kèm định danh của dãy. Danh sách này luôn được sắp theo giá trị tăng dần. Với phần tử mới x_i , tìm bằng nhị phân phần tử đầu tiên trong L có giá trị lớn hơn x_i . Nếu tìm thấy, nối x_i vào dãy tương ứng và thay giá trị cuối trong L bằng x_i . Nếu không tìm thấy, tạo một dãy mới và thêm (x_i, j) vào L .

Định lý. Phủ tham lam có thể xây dựng trong $O(n \log n)$. Đồng thời, một dãy con tăng dài nhất và một phủ nhỏ nhất cũng có thể được xây dựng trong $O(n \log n)$.

Với

$$\pi = (5, 3, 4, 9, 6, 2, 1, 8, 7, 10),$$

thuật toán tạo các dãy:

$$D_1 = (5, 3, 2, 1), \quad D_2 = (4), \quad D_3 = (9, 6), \quad D_4 = (8, 7), \quad D_5 = (10).$$

Phần giá trị của danh sách L lần lượt đi qua:

$$(5), (3), (3, 4), (3, 4, 9), (3, 4, 6), (2, 4, 6), \\ (1, 4, 6), (1, 4, 6, 8), (1, 4, 6, 7), (1, 4, 6, 7, 10).$$

6 Quy LCS về LIS

Cho hai dãy S_1 và S_2 . Gọi r_i là số lần xuất hiện của ký tự thứ i trong S_1 bên trong S_2 . Ví dụ:

$$S_1 = \text{abacx}, \quad S_2 = \text{baabca}.$$

Khi đó:

$$r(1) = 3, \quad r(2) = 2, \quad r(3) = 3, \quad r(4) = 1, \quad r(5) = 0.$$

Với mỗi ký tự phân biệt x trong S_1 , định nghĩa $\text{list}(x)$ là danh sách các vị trí của x trong S_2 , viết theo thứ tự giảm dần. Ví dụ:

$$\text{list}(a) = (6, 3, 2), \quad \text{list}(b) = (4, 1), \quad \text{list}(c) = (5), \quad \text{list}(x) = \emptyset.$$

Định nghĩa $\Pi(S_1, S_2)$ là dãy thu được bằng cách nối $\text{list}(s_i)$ với $i = 1, 2, \dots, n$, trong đó $n = |S_1|$ và s_i là ký tự thứ i của S_1 . Trong ví dụ:

$$\Pi(S_1, S_2) = (6, 3, 2, 4, 1, 6, 3, 2, 5).$$

Định lý. Mọi dãy con tăng I của $\Pi(S_1, S_2)$ xác định một dãy con chung của S_1 và S_2 có cùng độ dài, và ngược lại. Vì vậy một LCS của S_1 và S_2 tương ứng với một LIS của $\Pi(S_1, S_2)$.

Trong ví dụ trên, các dãy con tăng dài nhất của $\Pi(S_1, S_2)$ có thể dùng làm chỉ số truy cập vào S_2 để thu được các LCS:

$$(1, 2, 5) \mapsto \text{bac}, \quad (2, 3, 5) \mapsto \text{aac}, \quad (3, 4, 6) \mapsto \text{aba}.$$