

Bản trình chiếu: Tìm chuỗi con lặp lớn nhất

Lin Xide

2003

Nguồn gốc: Tìm chuỗi con lặp lớn nhất

IOI China candidate team papers / 2003 / Lin Xide / Lin Xide.ppt

1 Mục tiêu của bài trình bày

Bộ slide trình bày bài toán tìm chuỗi con lặp lớn nhất trong một chuỗi chữ cái in hoa. Nhiều trang gốc chứa hình ảnh hoặc đối tượng nhúng, nên bản ghi chú này tập trung vào nội dung thuật toán đã được bài viết đi kèm giải thích: định nghĩa chu kỳ, cây hậu tố, mở rộng KMP và cách kết hợp hai công cụ này để đạt thuật toán tuyến tính.

Các đoạn mã dài hoặc đối tượng nhúng trong nguồn gốc không được chép lại nguyên văn. Theo ngoại lệ về mẫu mã, bản dịch chỉ tóm tắt vai trò của chúng: cây hậu tố dùng để phân rã chuỗi, còn mở rộng KMP dùng để tính nhanh các độ dài khớp cần thiết.

2 Định nghĩa bài toán

Với chuỗi S , một số nguyên dương p là chu kỳ của S nếu

$$1 \leq x \leq |S| - p \implies S_x = S_{x+p}.$$

Khi đó

$$e = \frac{|S|}{p}$$

là số mũ của S . Nếu $e \geq 2$, ta gọi S là một chuỗi lặp kích thước p . Bài toán đặt ra: với chuỗi W độ dài

$$1 \leq n \leq 10^5,$$

tìm trong mọi chuỗi con của W một chuỗi lặp có chu kỳ lớn nhất.

Ký hiệu

$$W(u, v)$$

là chuỗi con bắt đầu tại vị trí u và kết thúc tại vị trí v . Cách trực tiếp là duyệt chu kỳ p từ lớn xuống nhỏ rồi kiểm tra có hai khối liên tiếp độ dài p giống nhau hay không. Cách này dễ hiểu nhưng tốn $O(n^2)$.

3 Cây hậu tố trong slide

Để xử lý mọi hậu tố trong thời gian tuyến tính, ta thêm ký tự kết thúc đặc biệt:

$$W \leftarrow W\$,$$

với \$ không xuất hiện trong chuỗi ban đầu. Cây hậu tố là trie nén của tất cả hậu tố $W(i, n)$. Mỗi cạnh $E(u, v)$ được ghi bằng cặp chỉ số

$$E(u, v) = (\ell, r),$$

biểu diễn nhãn cạnh là chuỗi con $W(\ell, r)$.

Nếu nối các nhãn trên đường từ gốc tới nút x , ta được chuỗi S_x . Mỗi hậu tố $W(i, n)$ ứng với một lá $Leaf_i$. Khi chèn hậu tố thứ i , đặt $Head_i$ là tiền tố chung dài nhất giữa $W(i, n)$ và một hậu tố đã chèn trước đó; phần còn lại là $Tail_i$. Cây hậu tố được cập nhật bằng cách tìm vị trí của $Head_i$, tách cạnh nếu cần, rồi thêm lá cho $Tail_i$.

Slide nhắc ý tưởng liên kết hậu tố của McCreight. Nếu

$$Head_{i-1} = az,$$

thì khi chuyển sang hậu tố kế tiếp, chuỗi z đã biết là một tiền tố xuất hiện trước đó. Liên kết hậu tố từ nút az sang nút z cho phép tìm $Head_i$ mà không quay lại gốc. Đại lượng

$$i + |Head_i|$$

không giảm, nên tổng số ký tự được duyệt là $O(n)$.

4 KMP và mở rộng KMP

KMP cổ điển dùng hàm tiền tố để tránh so sánh lại những ký tự đã biết. Trong bài toán này, ta cần nhiều giá trị độ dài khớp chứ không chỉ cần biết mẫu có xuất hiện hay không. Vì vậy slide dùng dạng mở rộng KMP, tương đương với việc tính các giá trị LCP kiểu Z-function.

Với mẫu T và chuỗi S , định nghĩa

$$B_i = \text{lcp}(T, S(i, n)).$$

Trước hết tính

$$A_i = \text{lcp}(T, T(i, m)),$$

rồi dùng đoạn khớp xa nhất đã biết để suy ra hoặc mở rộng từng B_i . Vì biên phải của đoạn khớp chỉ tăng, tổng số lần so sánh ký tự là tuyến tính.

Trong thuật toán chính, mở rộng KMP cung cấp nhanh hai loại thông tin: khớp tiền tố khi mở một chuỗi sinh sang phải, và khớp hậu tố khi mở sang trái trên chuỗi đảo.

5 Chuỗi con tối ưu

Với chuỗi con $S = W(u, v)$ và chu kỳ L , ta gọi S là chuỗi con tối ưu có chu kỳ L nếu:

- S có chu kỳ L ;
- không thể mở rộng S sang trái mà vẫn giữ chu kỳ L ;
- không thể mở rộng S sang phải mà vẫn giữ chu kỳ L .

Nếu liệt kê được các chuỗi con tối ưu và chu kỳ của chúng, đáp án là chuỗi có chu kỳ lớn nhất. Cách kiểm tra một chu kỳ L là chọn một chuỗi sinh độ dài L , mở rộng sang hai phía đến khi không còn khớp, rồi xem độ dài sau mở rộng có đạt ít nhất $2L$ hay không.

6 Phân rã chuỗi

Slide phân rã

$$W = U_1 + U_2 + \dots + U_m$$

theo quy tắc: nếu phần đã xử lý là

$$P = U_1 + \dots + U_{i-1}, \quad W = P + Q,$$

thì nếu ký tự đầu Q_1 chưa xuất hiện trong P , đặt $U_i = Q_1$; ngược lại, U_i là tiền tố dài nhất của Q đã xuất hiện trong P .

Ví dụ trong bài viết:

$$W = \text{ABAABABAABAAB}$$

có phân rã

$$|A|B|A|AB|ABAAB|AAB|.$$

Phân rã này được tính bằng cây hậu tố, vì mỗi U_i chính là một ký tự mới hoặc $Head_{|P|+1}$.

7 Giới hạn nơi có thể có nghiệm

Vai trò của phân rã là giới hạn vị trí của chuỗi con tối ưu. Xét một chuỗi con tối ưu S có điểm kết thúc nằm trong mảnh U_i . Nếu S bắt đầu trong chính U_i , nó đã xuất hiện trong phần trước theo định nghĩa của U_i , nên sẽ được xét ở bước trước đó. Trường hợp cần xét là S bắt đầu trước U_i và kết thúc trong U_i .

Đặt $U = U_i$, và đặt V là hậu tố của phần trước đó

$$P = U_1 + \dots + U_{i-1}$$

có độ dài

$$|U| + 2|U_{i-1}|.$$

Khi ấy mọi chuỗi con tối ưu kết thúc trong U đều có điểm bắt đầu nằm trong V . Nhờ vậy, thay vì xét toàn bộ chuỗi, ta chỉ cần xét các bài toán cục bộ trên $V + U$.

8 Tìm chuỗi sinh trong từng cục bộ

Với một cặp V, U , xét chu kỳ L . Nếu chuỗi con tối ưu bắt đầu trong V , kết thúc trong U , và có độ dài ít nhất $2L$, thì ít nhất một trong hai phần của nó nằm trong V hoặc U có độ dài không nhỏ hơn L . Hai trường hợp đối xứng; xét trường hợp phần nằm trong U đủ dài. Khi đó

$$U(1, L)$$

có thể được dùng làm chuỗi sinh, rồi mở rộng sang trái và sang phải.

Các đại lượng phụ trợ được slide dùng là

$$Lp_L = \text{lcp}(U, U(L+1, |U|))$$

và

$$Ls_L = \text{lcs}(V, V + U(1, L)).$$

Ở đây lcs là độ dài hậu tố chung dài nhất. Toàn bộ các giá trị Lp_L và Ls_L được tính bằng mở rộng KMP, nên chi phí bình quân cho mỗi L là $O(1)$.

9 Thuật toán tổng quát

Quy trình của bài trình bày có thể tóm tắt như sau:

1. Dựng cây hậu tố và phân rã W thành $U_1, \dots, U_m$.
2. Với mỗi $i \geq 2$, đặt $U = U_i$, chọn V là hậu tố của phần đã xử lý có độ dài $|U| + 2|U_{i-1}|$.
3. Tính các mảng mở rộng cho cặp V, U .
4. Với mọi $1 \leq L \leq |U|$, dùng $U(1, L)$ làm chuỗi sinh, mở rộng bằng Lp_L và Ls_L , rồi kiểm tra độ dài sau mở rộng có ít nhất $2L$ hay không.
5. Làm tương tự cho trường hợp đối xứng khi phần dài nằm trong V .
6. Cập nhật đáp án bằng chu kỳ lớn nhất tìm được.

Tổng độ dài các mảnh U_i là $O(n)$, còn cách chọn V bảo đảm tổng chi phí của mọi bài toán cục bộ cũng tuyến tính. Vì vậy toàn bộ thuật toán chạy trong $O(n)$ thời gian và dùng $O(n)$ bộ nhớ.

10 Tổng kết

Bài trình bày không chỉ giới thiệu cây hậu tố hoặc KMP riêng lẻ. Điểm chính là cách phối hợp chúng: cây hậu tố tạo ra một phân rã làm hẹp vùng có thể chứa nghiệm, còn mở rộng KMP cho phép kiểm tra tất cả chu kỳ trong từng vùng với tổng chi phí tuyến tính. Nhờ đó một bài toán nhìn ban đầu giống tìm kiếm mọi chuỗi con $O(n^2)$ được đưa về thuật toán $O(n)$.